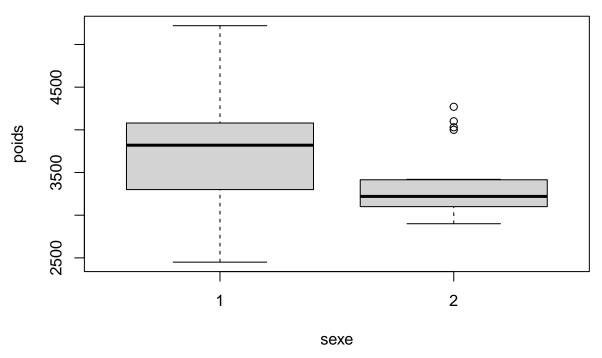
Statistique bayésienne avec R

Exercice sur les poids de naissance

Julien JACQUES

```
data=read.table('Rcode/poidsnaissance.txt',header = T,sep=',',row.names = 1)
data$OBS=NULL
sexe=data$SEXE+1
poids=data$POIDNAIS
boxplot(poids~sexe,main="poids de naissance")
```

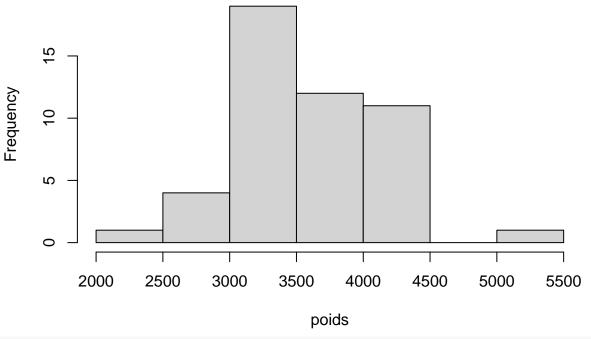
poids de naissance



L'histogramme du poids de naissance ressemble à peu près à une loi gaussienne, ce qui est confirmé par le test de Shapiro

hist(poids)

Histogram of poids



shapiro.test(poids)

```
##
## Shapiro-Wilk normality test
##
## data: poids
## W = 0.96218, p-value = 0.1237
```

Estimation bayésienne

Estimer le poids de naissance moyen

De façon fréquentiste :

mean(poids)

[1] 3590

Les données étant distribuées suivant une loi gaussienne, nous allons choisir un a priori conjugué gaussien. Il nous reste à déterminer les moyennes et variances a priori.

L'histogramme nous donne l'idée d'un a priori gaussien centré en 3250g. Pour l'écart-type, il va traduire la confiance que l'on a dans notre a priori.

Nous avons vu que le MAP est alors donné par :

$$\hat{\theta} = E[\theta | \underline{x}] = \frac{\tau^2 \frac{\sigma^2}{n}}{\tau^2 + \frac{\sigma^2}{n}} \left(\frac{\bar{x}}{\frac{\sigma^2}{n}} + \frac{\mu}{\tau^2} \right)$$

dont on peut coder le calcul. En jouant sur la valeur de l'ecart-type a priori τ , on pourra jouer sur la confiance en notre a priori et examiner son influence sur le MAP

```
s=sd(poids)
tau=100
n=length(poids)
MAP=(tau^2*s^2/n)/(tau^2+s^2/n)*(mean(poids)/(s^2/n)+3250/(tau^2))
print(MAP)
```

```
## [1] 3461.82
```

Le choix de τ est ici très subjectif, mais on n'a pas le choix car pas d'information supplémentaire. Si dans l'étude Statista2021 on avait pu avoir une idée de l'incertitude sur l'estimation du poids moyen, on aurait pu l'utiliser ici pour choisir τ .

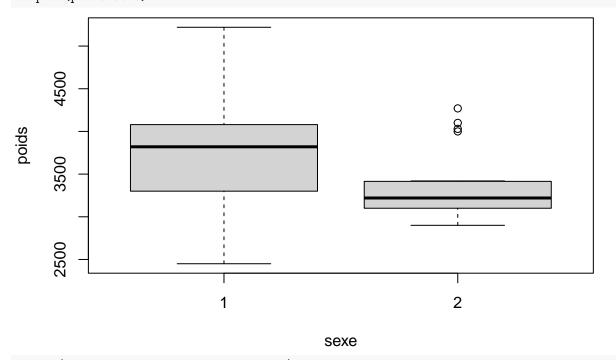
Les calculs sont faits ici à la main, nous verrons plus tard comment les faire sous R.

Test d'hypothèse et comparaison bayésienne de modèles

les garçons sont-ils plus lourds que les filles à la naissance ?

De façon fréquentiste c'est significatif,

boxplot(poids~sexe)



```
t.test(poids~sexe,alternative='greater')
```

```
## 3728.103 3379.211
```

Pour la version bayesienne, on indiquera l'unilatéralité de l'hypothèse alternative en specifiant nullInterval=c(0, Inf)

```
library(BayesFactor)
ttestBF(poids[sexe==1],poids[sexe==2],nullInterval=c(0, Inf))

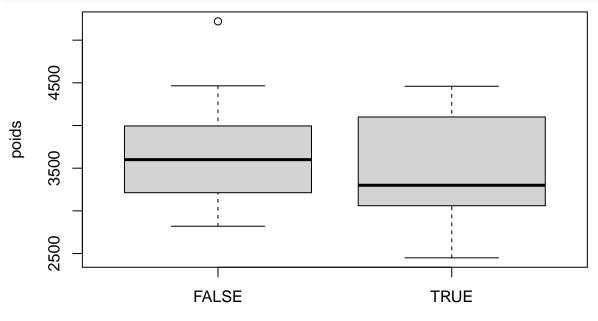
## Bayes factor analysis
## ------
## [1] Alt., r=0.707 0<d<Inf : 4.525689 ±0%
## [2] Alt., r=0.707 !(0<d<Inf) : 0.1017375 ±0%
##
## Against denominator:
## Null, mu1-mu2 = 0
## ---
## Bayes factor type: BFindepSample, JZS
Le facteur de Bayes faut 4.525689
log10(4.525689)</pre>
```

[1] 0.6556847

De façon bayesienne, c'est substantielle (!), il est difficile de conclure à la supériorité de poids des garçons par rapport aux filles.

le poids de naissance dépend-il du fait que la mère soit fumeuse?

```
fumeuse=data$CIGJOUR>0
boxplot(poids~fumeuse)
```



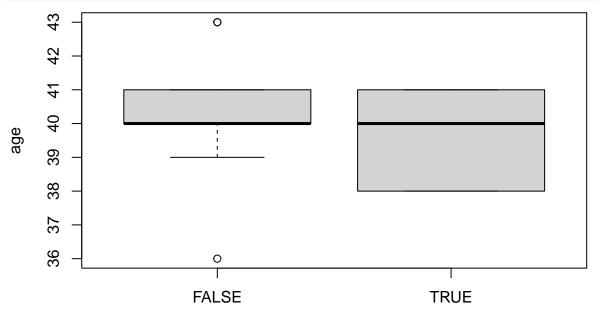
t.test(poids~fumeuse,alternative='greater')

##
Welch Two Sample t-test

fumeuse

```
##
## data: poids by fumeuse
## t = 0.53947, df = 10.414, p-value = 0.3005
## alternative hypothesis: true difference in means between group FALSE and group TRUE is greater than
## 95 percent confidence interval:
##
   -295.1788
## sample estimates:
## mean in group FALSE mean in group TRUE
              3613.590
                                  3487.778
ttestBF(poids[fumeuse],poids[!fumeuse],nullInterval=c(-Inf,0))
## Bayes factor analysis
## -----
## [1] Alt., r=0.707 -Inf<d<0
                                 : 0.5668229 ±0%
## [2] Alt., r=0.707 ! (-Inf < d < 0) : 0.2385683 \pm 0\%
##
## Against denominator:
    Null, mu1-mu2 = 0
## ---
## Bayes factor type: BFindepSample, JZS
Non significatif.
l'âge gestationnel dépend-il du fait que la mère soit fumeuse?
```

```
age=data$AGEGEST
boxplot(age~fumeuse)
```



```
t.test(age~fumeuse,alternative='greater')
```

fumeuse

Welch Two Sample t-test

```
## data: age by fumeuse
## t = 0.96285, df = 11.094, p-value = 0.1781
## alternative hypothesis: true difference in means between group FALSE and group TRUE is greater than
## 95 percent confidence interval:
## -0.3986471
## sample estimates:
## mean in group FALSE mean in group TRUE
                                  39.66667
              40.12821
ttestBF(age[fumeuse],age[!fumeuse],nullInterval=c(-Inf,0))
## Bayes factor analysis
## -----
## [1] Alt., r=0.707 -Inf<d<0
                                 : 0.84529
## [2] Alt., r=0.707 ! (-Inf < d < 0) : 0.1953459 \pm 0\%
##
## Against denominator:
##
   Null, mu1-mu2 = 0
## ---
## Bayes factor type: BFindepSample, JZS
Non significatif.
```

Régression linéaire

Effectuer une régression du poids de naissance en fonction des autres variables disponibles

```
De façon fréquentiste
m1=lm(POIDNAIS~.,data=data)
summary(m1)
##
## lm(formula = POIDNAIS ~ ., data = data)
## Residuals:
       Min
                 1Q
                    Median
                                   30
                                           Max
## -1039.65 -192.17
                      -33.47
                               187.49 1277.90
## Coefficients:
              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 621.107
                         3050.952
                                  0.204 0.83969
## AGEGEST
               164.131
                          57.489
                                    2.855 0.00672 **
## SEXE
              -422.069
                         145.419
                                  -2.902 0.00593 **
## CIGJOUR
                -2.552
                           5.493
                                   -0.465 0.64472
## TAILMERE
               -28.560
                           14.524
                                   -1.966 0.05605
## POIDAVG
               -17.229
                           17.021 -1.012 0.31737
## POIDFING
                30.330
                           13.433
                                   2.258 0.02934 *
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
## Residual standard error: 459.7 on 41 degrees of freedom
## Multiple R-squared: 0.3654, Adjusted R-squared: 0.2725
```

```
## F-statistic: 3.935 on 6 and 41 DF, p-value: 0.003388
m2=step(m1)
## Start: AIC=594.96
## POIDNAIS ~ AGEGEST + SEXE + CIGJOUR + TAILMERE + POIDAVG + POIDFING
##
             Df Sum of Sq
                              RSS
                                     AIC
## - CIGJOUR 1 45599 8708906 593.22
## - POIDAVG 1
                   216495 8879803 594.15
## <none>
                          8663308 594.96
## - TAILMERE 1 817055 9480362 597.29
## - POIDFING 1 1077169 9740477 598.59
## - AGEGEST 1 1722285 10385593 601.67
              1 1780026 10443334 601.93
## - SEXE
##
## Step: AIC=593.22
## POIDNAIS ~ AGEGEST + SEXE + TAILMERE + POIDAVG + POIDFING
             Df Sum of Sq
                              RSS
                                     AIC
            1 194586 8903492 592.28
## - POIDAVG
## <none>
                          8708906 593.22
## - TAILMERE 1
                 820823 9529730 595.54
## - POIDFING 1 1031572 9740478 596.59
## - SEXE
             1 1821002 10529908 600.33
            1 1864248 10573155 600.53
## - AGEGEST
##
## Step: AIC=592.28
## POIDNAIS ~ AGEGEST + SEXE + TAILMERE + POIDFING
##
##
                                     AIC
             Df Sum of Sq
                              RSS
## <none>
                          8903492 592.28
## - TAILMERE 1 846954 9750446 594.64
## - POIDFING 1 1429451 10332943 597.42
## - AGEGEST 1 1929166 10832659 599.69
## - SEXE
              1 2367275 11270767 601.59
summary(m2)
##
## Call:
## lm(formula = POIDNAIS ~ AGEGEST + SEXE + TAILMERE + POIDFING,
      data = data)
##
##
## Residuals:
       Min
                 1Q Median
                                  3Q
## -1168.11 -184.86 -20.26 186.56 1216.36
## Coefficients:
              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 306.933 3000.300 0.102 0.91899
## AGEGEST
              171.179
                        56.080
                                  3.052 0.00388 **
## SEXE
              <del>-465</del>.)769
                       137.750 -3.381 0.00155 **
             -29.063 14.370 -2.022 0.04937 *
## TAILMERE
```

2.627 0.01188 *

18.413

7.008

POIDFING

```
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
## Residual standard error: 455 on 43 degrees of freedom
## Multiple R-squared: 0.3478, Adjusted R-squared: 0.2871
## F-statistic: 5.733 on 4 and 43 DF, p-value: 0.0008655
De façon bayesienne
y=data$POIDNAIS
x=as.matrix(data[,-3])
summary(lm(y~x))
##
## Call:
## lm(formula = y \sim x)
##
## Residuals:
##
        Min
                   1Q
                        Median
                                     3Q
                                              Max
## -1039.65 -192.17
                        -33.47
                                 187.49
                                         1277.90
##
## Coefficients:
               Estimate Std. Error t value Pr(>|t|)
                           3050.952
## (Intercept)
               621.107
                                      0.204 0.83969
## xAGEGEST
                164.131
                             57.489
                                      2.855 0.00672 **
                            145.419
## xSEXE
               -422.069
                                     -2.902 0.00593 **
## xCIGJOUR
                              5.493
                                     -0.465
                                             0.64472
                 -2.552
## xTAILMERE
                -28.560
                             14.524
                                     -1.966 0.05605
                -17.229
                                     -1.012 0.31737
## xPOIDAVG
                             17.021
## xPOIDFING
                 30.330
                             13.433
                                      2.258 0.02934 *
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 459.7 on 41 degrees of freedom
## Multiple R-squared: 0.3654, Adjusted R-squared: 0.2725
## F-statistic: 3.935 on 6 and 41 DF, p-value: 0.003388
Je vais introduire un a priori sur le fait que fumer une 10 cigarettes par jour fait perdre 100g au poids de
naissance (donc -10g par cigarette) et que les garçons sont aussi lourds que les filles. Comme je ne veux pas
toucher aux autres variables, je donne comme a priori l'estimation du max de vraisemblance. Et comme je
suis sûr de moi, je mets g = 1
```

```
library(bayess)
res1=BayesReg(y,x,betatilde = c(164,-422,-10,-28,-17,30),g=1)
```

```
##
##
              PostMean PostStError Log10bf EvidAgaH0
## Intercept 3590.0000
                            70.5637
                            51.4271
                                                 (***)
## x1
              179.6175
                                    1.3474
## x2
             -314.2020
                            53.4801 0.5897
                                                  (**)
## x3
              -21.0516
                            51.9705 -0.1176
## x4
              -82.7004
                            52.5473 0.3658
                                                   (*)
## x5
              -76.6759
                           101.3032 -0.0246
              165.8403
                           100.4829 0.4398
                                                   (*)
## x6
##
##
```

```
## Posterior Mean of Sigma2: 239003.0691
## Posterior StError of Sigma2: 341820.7276
Avec une régression LASSO
library('lars')
model_lasso=lars(x,y,type="lasso",trace=F,normalize=TRUE)
plot(model_lasso,xvar='df', plottype='coeff')
                                   LASSO
          0
                             2
                                      3
                                                        5
                                                                  6
    1500
Standardized Coefficients
    -500
    -1500
                    2
                             3
                                               5
                                                        6
                                      4
                                      Df
cv=cv.lars(x,y,K=48,
            trace=F,plot.it=T,se=T,type=c("lasso"),
            mode='step',normalize=TRUE)
Cross-Validated MSE
     300000
     200000
                                      (4)
           1
                     2
                              3
                                                  5
                                                           6
                                                                     7
                                 Number of steps
                                                                         Le minimum est à l'étape 5,
néanmoins l'étape 4 donne une erreur pas significativement plus grande que celle de l'étape 5...
print(model_lasso$lambda[4])
## [1] 581.9842
print(model_lasso$beta[4,])
##
        AGEGEST
                         SEXE
                                    CIGJOUR
                                                 TAILMERE
                                                               POIDAVG
                                                                            POIDFING
     73.993249 -210.877346
                                  0.000000
                                                 0.000000
                                                              0.00000
                                                                            3.797626
```

Seules 3 variables sont sélectionnées (agegest, sexe, poidfing). Pour terminer, nous ré-estimons un modèle de régression classique sur ces 3 variables :

```
m3=lm(POIDNAIS~AGEGEST+SEXE+POIDFING, data=data)
summary(m3)
##
## Call:
## lm(formula = POIDNAIS ~ AGEGEST + SEXE + POIDFING, data = data)
## Residuals:
##
       Min
                  1Q
                      Median
                                   30
                                            Max
## -1244.88 -228.25
                       -32.43
                                213.42
                                       1429.99
##
## Coefficients:
##
                Estimate Std. Error t value Pr(>|t|)
## (Intercept) -3601.977
                           2374.076
                                    -1.517 0.13637
## AGEGEST
                 156.539
                             57.531
                                     2.721 0.00929 **
                            141.978
## SEXE
                441.818
                                    -3.112 0.00326 **
## POIDFING
                  14.280
                              6.935
                                     2.059 0.04542 *
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
## Residual standard error: 470.7 on 44 degrees of freedom
## Multiple R-squared: 0.2858, Adjusted R-squared: 0.2371
## F-statistic: 5.868 on 3 and 44 DF, p-value: 0.001842
```

Modélisation hierarchique

```
On commence par définir les données
```

```
dat <- list(poids = poids, sexe = sexe, N = length(poids))
Puis 3 initialisations différentes
inits <- list( list(moyennes = c(2600, 4000), sigma = 500), list(moyennes = c(4500, 2700), sigma = 700),
On définit le modèle
library(rjags)
## Linked to JAGS 4.3.0
## Loaded modules: basemod,bugs
m1 <- jags.model('Rcode/modelepoidsnaissance.txt', data = dat, inits = inits, n.chains = 3, quiet=TRUE)
Puis on lance les itérations MCMC</pre>
```

```
update(m1, 3000,progress.bar="none")
mcmc1 <- coda.samples(m1, variable.names = c("moyennes", "sigma"), n.iter = 2000,progress.bar="none")</pre>
```

Comme résultat on peut regarder par exemple la moyenne du poids moyen des garçons :

```
mean(mcmc1[[1]][, "moyennes[1]"])
```

[1] 3728.453

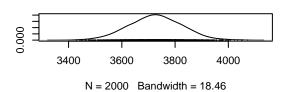
On peut représenter les chaînes MCMC

plot(mcmc1)

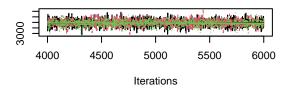
Trace of moyennes[1]

4000 4500 5000 5500 6000 Iterations

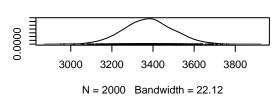
Density of moyennes[1]



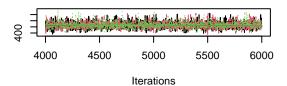
Trace of moyennes[2]



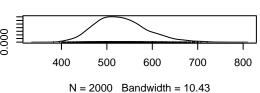
Density of moyennes[2]



Trace of sigma



Density of sigma



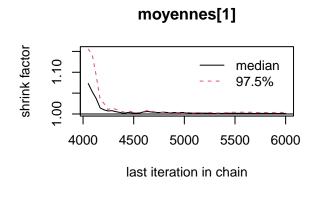
Les diag-

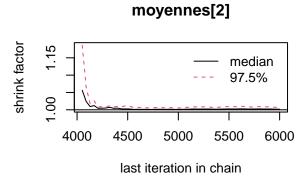
nostiques de convergence permettent de vérifier que la période de chauffe était suffisament longue gelman.diag(mcmc1)

Potential scale reduction factors: ## Point est. Upper C.I. ## moyennes[1] 1.00 ## 1 moyennes[2] 1 1.01 1.00 ## sigma 1 ## ## Multivariate psrf

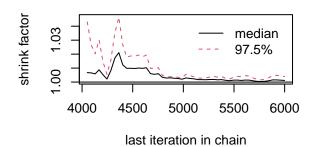
gelman.plot(mcmc1)

1

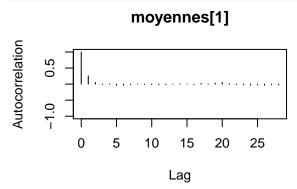


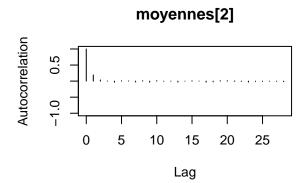


sigma

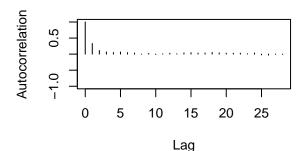


autocorr.plot(mcmc1[[1]])





sigma

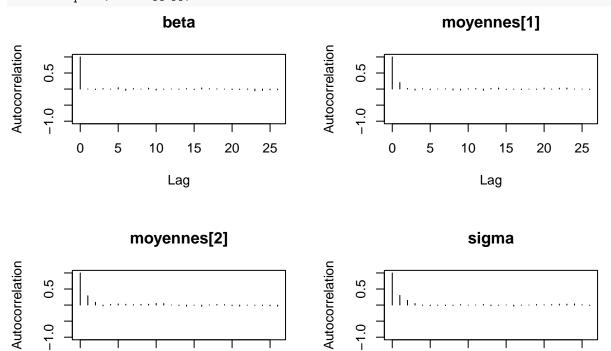


peut finalement examiner les résultats (loi a posteriori des paramètres) :

```
summary(mcmc1)
## Iterations = 4001:6000
## Thinning interval = 1
## Number of chains = 3
## Sample size per chain = 2000
##
## 1. Empirical mean and standard deviation for each variable,
##
      plus standard error of the mean:
##
##
                 Mean
                           SD Naive SE Time-series SE
## moyennes[1] 3726.1 100.26
                                1.2943
                                                1.615
## moyennes[2] 3378.5 120.96
                                1.5616
                                                1.915
                                                1.048
## sigma
                530.8 56.91
                                0.7347
##
## 2. Quantiles for each variable:
                 2.5%
##
                          25%
                                 50%
                                        75% 97.5%
## moyennes[1] 3530.3 3660.4 3726.0 3793.4 3922.3
## moyennes[2] 3144.0 3297.6 3377.5 3456.9 3618.7
## sigma
                433.8 490.2 525.9 565.3 658.9
Modèle avec le sexe et la taille de la mère
On commence par définir les données
dat <- list(poids = poids, sexe = sexe, N = length(poids), taille=data$TAILMERE)</pre>
Puis 3 initialisations différentes
inits <- list(list(moyennes = c(2600, 4000), sigma = 500, beta=10), list(moyennes = c(4500, 2700), sigm
On définit le modèle
library(rjags)
m1b <- jags.model('Rcode/modelepoidsnaissance4.txt', data = dat, inits = inits, n.chains = 3, quiet=TRU
Puis on lance les itérations MCMC
update(m1b, 3000,progress.bar="none")
mcmc1b <- coda.samples(m1b, variable.names = c("moyennes", "sigma", "beta"), n.iter = 2000, progress.bar=
On vérifie que les chaines ont bien convergées.
gelman.diag(mcmc1b)
## Potential scale reduction factors:
##
               Point est. Upper C.I.
##
## beta
                        1
                                    1
## moyennes[1]
                         1
                                    1
## moyennes[2]
                         1
                                    1
## sigma
                         1
                                    1
##
## Multivariate psrf
##
```

1

autocorr.plot(mcmc1b[[1]])



5

10

15

Lag

20

25

0

Regardons les estimations

0

5

10

15

Lag

20

25

summary(mcmc1b)

```
##
## Iterations = 4001:6000
## Thinning interval = 1
## Number of chains = 3
  Sample size per chain = 2000
##
##
  1. Empirical mean and standard deviation for each variable,
##
      plus standard error of the mean:
##
##
                   Mean
                              SD Naive SE Time-series SE
                  3.111
                           8.492
                                   0.1096
                                                  0.1096
## beta
## moyennes[1] 3730.680
                         98.143
                                   1.2670
                                                  1.5930
## moyennes[2] 3379.290 123.389
                                   1.5929
                                                  2.1083
  sigma
                533.214
                         58.345
                                   0.7532
##
                                                   1.1414
##
## 2. Quantiles for each variable:
##
##
                  2.5%
                                      50%
                                               75%
                             25%
                                                     97.5%
                -13.44
                         -2.624
                                    2.979
                                             8.836
                                                      19.62
## moyennes[1] 3542.78 3663.182 3728.252 3796.311 3929.02
## moyennes[2] 3134.19 3296.038 3379.958 3461.971 3615.98
## sigma
                434.89 492.315 527.650
                                           568.848
                                                    662.25
```

```
#plot(mcmc1b)
Le beta ne semble pas significatif.
Calculons le DIC pour comparer à celui du modèle sans la taille
dic.samples(m1, n.iter=1000)
## Mean deviance: 737
## penalty 3.124
## Penalized deviance: 740.1
dic.samples(m1b, n.iter=1000)
## Mean deviance: 737.9
## penalty 3.577
## Penalized deviance: 741.5
Modèle avec le sexe, l'âge gestationnel et le nombre de cigarettes
On va faire de même mais en intégrant la variable agegest, supposé avoir un effet sur le poids mu_i, ainsi que
la variable cigjour supposé avec un effet elle sur la variable agegest
data=read.table('Rcode/poidsnaissance.txt',header = T,sep=',')
sexe=data$SEXE+1
poids=data$POIDNAIS
nbsemaines=data$AGEGEST
nbcig=data$CIGJOUR
definiton des donnees
dat <- list(poids = poids, sexe = sexe, nbsemaines = nbsemaines, nbcig=nbcig, N = length(poids))
initialisation
inits <- list(</pre>
  list(moyennes = c(2600, 4000), sigma = 500, b=150, b2 = -1,b3=0),
  list(moyennes = c(4500, 2700), sigma = 700, b=100, b2 = 0,b3=0),
  list(movennes = c(4000, 4000), sigma = 300, b=200, b2 = 1,b3=0))
definition modele
```

```
m2 <- jags.model('Rcode/modelepoidsnaissance2.txt', data = dat, inits = inits, n.chains = 3, quiet=TRUE
```

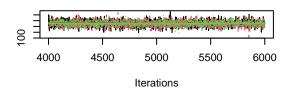
iterations de MCMC

```
update(m2, 3000,progress.bar="none")
mcmc1 <- coda.samples(m2, variable.names = c("moyennes", "sigma","b","b2","b3"), n.iter = 2000,progress</pre>
```

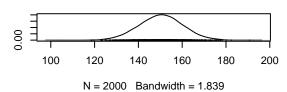
représentation de la chaine

plot(mcmc1)

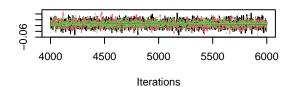




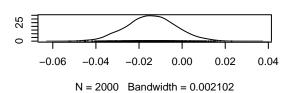
Density of b



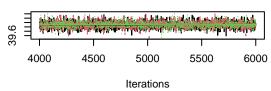
Trace of b2



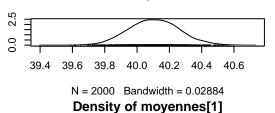
Density of b2



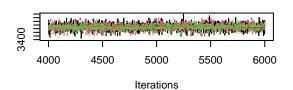
Trace of b3

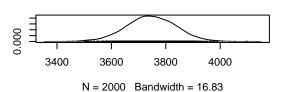


Density of b3

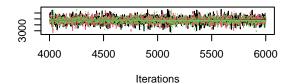


Trace of moyennes[1]

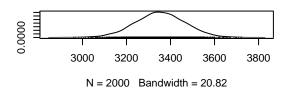




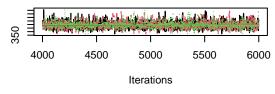
Trace of moyennes[2]



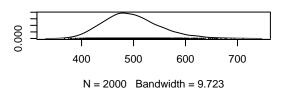
Density of moyennes[2]



Trace of sigma



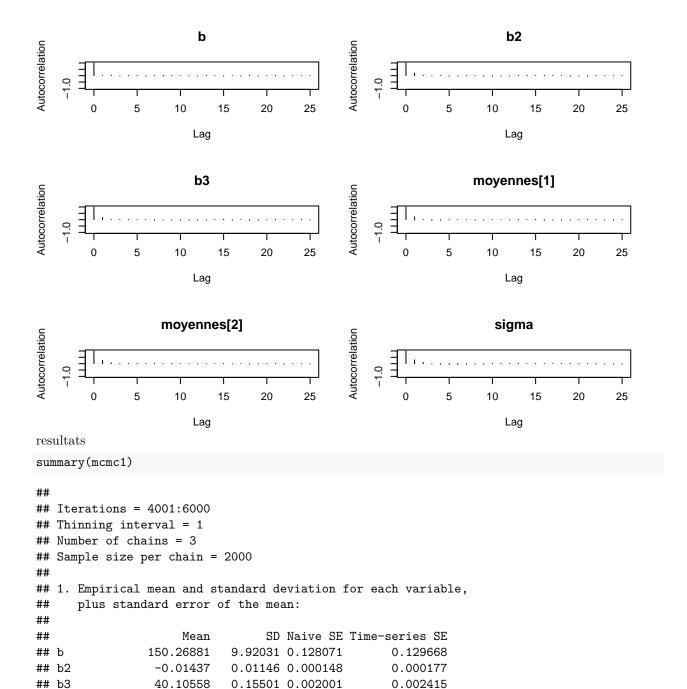
Density of sigma



diag-

nostique de convergence

gelman.diag(mcmc1) ## Potential scale reduction factors: ## ## Point est. Upper C.I. ## b 1 1 ## b2 1 1 ## b3 1 1 ## moyennes[1] 1 1 moyennes[2] 1 ## sigma 1 ## ## Multivariate psrf ## ## 1 gelman.plot(mcmc1) b b2 shrink factor shrink factor median median 4000 4500 5000 4000 4500 5000 5500 6000 5500 6000 last iteration in chain last iteration in chain b3 moyennes[1] shrink factor shrink factor median median 4000 4500 5000 4000 4500 5500 6000 5000 5500 6000 last iteration in chain last iteration in chain moyennes[2] sigma shrink factor shrink factor median median 4000 4500 5000 5500 6000 4000 4500 5000 5500 6000 last iteration in chain last iteration in chain autocorr.plot(mcmc1[[1]])



```
496.66332
                           54.05450 0.697841
##
  sigma
                                                     0.889532
##
  2. Quantiles for each variable:
##
                    2.5%
                                 25%
                                            50%
                                                        75%
##
                                                                97.5%
## b
                130.5465
                           143.60516
                                      150.34991
                                                 1.568e+02 1.697e+02
## b2
                 -0.0366
                            -0.02189
                                       -0.01445 -6.757e-03 8.511e-03
## b3
                 39.8120
                            39.9959
                                       40.10456
                                                 4.021e+01 4.041e+01
## moyennes[1] 3567.4450 3685.94826 3745.74580
                                                 3.808e+03 3.923e+03
## moyennes[2] 3123.0865 3277.84172 3352.22706
                                                 3.428e+03 3.574e+03
```

90.47462 1.168022

moyennes[1] 3745.66612

moyennes[2] 3352.46765 114.26711 1.475182

1.423645

1.905846

```
405.0113 458.92001 491.91667 5.289e+02 6.188e+02
## sigma
On peut comparer les modèle à l'aide du critère DIC. Le critère DIC est un critère de déviance (-2 loglik +
cste) pénalisée par la complexité du modèle. Le critère DIC doit être le plus petit possible.
dic.samples(m1, n.iter=1000)
## Mean deviance: 736.9
## penalty 3.106
## Penalized deviance: 740
dic.samples(m2, n.iter=1000)
## Mean deviance: 887
## penalty 5.153
## Penalized deviance: 892.2
Modèle avec l'age de gestation et le sexe :
dat <- list(poids = poids, sexe = sexe, nbsemaines = nbsemaines, N = length(poids))
inits <- list(</pre>
  list(moyennes = c(2600, 4000), sigma = 500, b=150),
 list(moyennes = c(4500, 2700), sigma = 700, b=100),
 list(moyennes = c(4000, 4000), sigma = 300, b=200))
m3 <- jags.model('Rcode/modelepoidsnaissance3.txt', data = dat, inits = inits, n.chains = 3, quiet=TRUE
update(m3, 3000,progress.bar="none")
mcmc1 <- coda.samples(m3, variable.names = c("moyennes", "sigma", "b"), n.iter = 2000, progress.bar="none
dic.samples(m3, n.iter=1000)
## Mean deviance: 731.4
## penalty 4.023
## Penalized deviance: 735.4
Le critère DIC est meilleur.
On vérifie la convergence
gelman.diag(mcmc1)
## Potential scale reduction factors:
##
               Point est. Upper {\tt C.I.}
##
## b
                         1
## moyennes[1]
                         1
                                     1
## moyennes[2]
                         1
                                     1
## sigma
                         1
                                     1
## Multivariate psrf
##
## 1
```

0

5

10

15

Lag

20

25

5

10

15

Lag

20

25

0

```
On compare le critère DIC :
dic.samples(m3, n.iter=1000)
## Mean deviance: 731.5
## penalty 4.088
## Penalized deviance: 735.6
Examinons les estimations obtenues
summary(mcmc1)
##
## Iterations = 4001:6000
## Thinning interval = 1
## Number of chains = 3
## Sample size per chain = 2000
##
## 1. Empirical mean and standard deviation for each variable,
      plus standard error of the mean:
##
##
                 Mean
                          SD Naive SE Time-series SE
## b
                154.4 58.90
                               0.7604
                                               0.9999
## moyennes[1] 3746.5 95.40
                                               1.5875
                               1.2316
## moyennes[2] 3349.9 118.31
                                               2.1222
                               1.5273
## sigma
                500.8 53.96
                               0.6966
                                               0.9769
##
## 2. Quantiles for each variable:
##
##
                  2.5%
                          25%
                                 50%
                                        75% 97.5%
## b
                 40.45 112.9 154.8 194.8 270.8
## moyennes[1] 3564.90 3680.7 3745.4 3809.2 3934.3
## moyennes[2] 3118.87 3269.9 3350.7 3428.9 3579.4
## sigma
                406.58 462.6 496.6 534.3 619.8
Modèle avec l'age de gestation, le sexe et la prise de poids de la mère :
prisepoids=data$POIDFING-data$POIDAVG
dat <- list(poids = poids, sexe = sexe, nbsemaines = nbsemaines, N = length(poids), prisepoids=prisepoids
inits <- list(</pre>
  list(movennes = c(2600, 4000), sigma = 500, b=150, c=-100),
  list(moyennes = c(4500, 2700), sigma = 700, b=100, c=0),
  list(moyennes = c(4000, 4000), sigma = 300, b=200, c=100))
m5 <- jags.model('Rcode/modelepoidsnaissance5.txt', data = dat, inits = inits, n.chains = 3, quiet=TRUE
update(m5, 3000,progress.bar="none")
mcmc1 <- coda.samples(m5, variable.names = c("moyennes", "sigma", "b", "c"), n.iter = 2000, progress.bar=":
On vérifie la convergence
gelman.diag(mcmc1)
## Potential scale reduction factors:
##
##
               Point est. Upper C.I.
## b
                        1
                                   1
## c
```

1

1

1

1

moyennes[1]

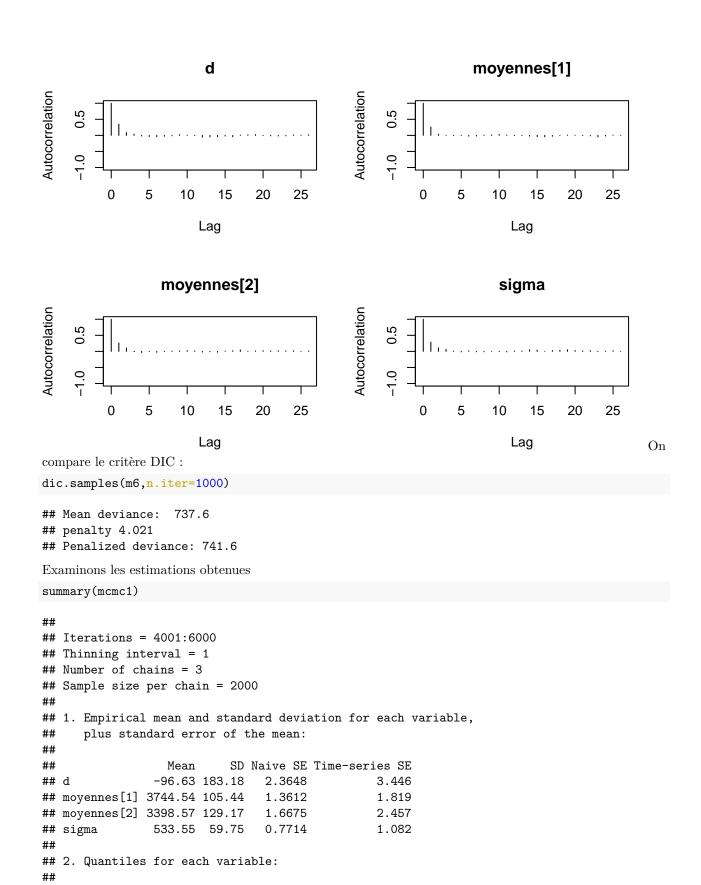
```
## moyennes[2]
                             1
## sigma
##
## Multivariate psrf
##
## 1
autocorr.plot(mcmc1[[1]])
                            b
                                                                                   С
                                                      Autocorrelation
Autocorrelation
                                                           -1.0
    -1.0
                 5
                       10
                               15
                                      20
                                             25
                                                                       5
                                                                              10
                                                                                      15
                                                                                             20
                                                                                                    25
                           Lag
                                                                                  Lag
                      moyennes[1]
                                                                            moyennes[2]
                                                      Autocorrelation
Autocorrelation
                                                           -1.0
    -1.0
                       10
                                      20
                                             25
                                                                              10
                 5
                               15
                                                                       5
                                                                                      15
                                                                                             20
                                                                                                    25
                           Lag
                                                                                  Lag
                         sigma
Autocorrelation
    -1.0
         0
                5
                       10
                               15
                                      20
                                             25
                           Lag
On compare le critère DIC :
dic.samples(m5, n.iter=1000)
## Mean deviance: 728
## penalty 5.132
## Penalized deviance: 733.1
Examinons les estimations obtenues
summary(mcmc1)
##
## Iterations = 4001:6000
## Thinning interval = 1
   Number of chains = 3
   Sample size per chain = 2000
##
##
   1. Empirical mean and standard deviation for each variable,
##
       plus standard error of the mean:
##
                                 SD Naive SE Time-series SE
##
                      Mean
```

```
## b
                153.61 57.73
                               0.7454
                                              0.9560
## c
                27.31 13.89
                               0.1793
                                               0.2294
                               1.1443
                                               1.4891
## moyennes[1] 3732.64 88.64
## moyennes[2] 3371.42 113.36
                               1.4635
                                               1.8744
## sigma
               483.57 52.55
                               0.6785
                                               0.9767
##
## 2. Quantiles for each variable:
##
##
                    2.5%
                             25%
                                     50%
                                             75%
                                                   97.5%
## b
                41.9658 114.36 152.69
                                         192.57
                                                  269.19
## c
                -0.4718
                          17.97
                                  27.36
                                           36.72
                                                   54.42
## moyennes[1] 3560.0528 3675.00 3732.58 3790.10 3909.17
## moyennes[2] 3149.0676 3294.08 3371.19 3447.60 3594.15
## sigma
               395.0080 445.41 479.37 516.21 598.02
Modèle avec le sexe et un impact du fait d'être fumeur sur le poids moyen :
fumeur=data$CIGJOUR>0
dat <- list(poids = poids, sexe = sexe, fumeur = fumeur, N = length(poids))
inits <- list(</pre>
  list(moyennes = c(2600, 4000), sigma = 500, d=100),
  list(moyennes = c(4500, 2700), sigma = 700, d=0),
 list(moyennes = c(4000, 4000), sigma = 300, d=-100))
m6 <- jags.model('Rcode/modelepoidsnaissance6.txt', data = dat, inits = inits, n.chains = 3, quiet=TRUE
update(m6, 3000,progress.bar="none")
mcmc1 <- coda.samples(m6, variable.names = c("moyennes", "sigma", "d"), n.iter = 2000, progress.bar="none
```

On vérifie la convergence

```
gelman.diag(mcmc1)
```

```
## Potential scale reduction factors:
##
               Point est. Upper C.I.
                                 1.01
                         1
                                 1.00
## moyennes[1]
                         1
## moyennes[2]
                         1
                                 1.00
## sigma
                         1
                                 1.00
## Multivariate psrf
##
## 1
autocorr.plot(mcmc1[[1]])
```



75% 97.5% 30.63 269.4

##

d

2.5%

25%

-434.9 -228.3 -101.1

50%

```
## moyennes[1] 3534.9 3676.2 3746.0 3813.88 3951.5
## moyennes[2] 3147.7 3313.5 3398.6 3483.36 3654.9
## sigma 432.9 492.1 527.6 570.77 664.7
```